UNIVERSIDAD NACIONAL
DE ROSARIO
FACULTAD DE CIENCIAS
ECONÓMICAS Y ESTADÍSTICA



UNR

Trabajo Práctico de Modelos Lineales Generalizados

Integrantes:
Cañizares, María Inés
Zamer, Lisbeth

Licenciatura en Estadística

Año 2026

Introducción

El hundimiento del RMS Titanic, ocurrido en 1912 durante su viaje inaugural, es una de las tragedias marítimas más recordadas de la historia. Considerado el mayor transatlántico de su época y casi insumergible, su naufragio causó la muerte de más de 1.500 de las aproximadamente 2.200 personas a bordo y dejó en evidencia graves falencias de seguridad, como la escasez de botes salvavidas. El suceso provocó una conmoción mundial e impulsó cambios en la normativa internacional. Los datos de sus pasajeros permiten, además, estudiar si la supervivencia estuvo asociada a características individuales como el sexo, la edad, la tarifa abonada o el puerto de embarque, y contrastar con evidencia empírica la norma de "mujeres y niños primero".

En este trabajo se busca identificar los factores con mayor influencia en la probabilidad de supervivencia de los pasajeros, mediante un Modelo Lineal Generalizado sobre la base de datos del Titanic construida a partir de registros históricos reales.

Material y métodos

En este contexto, el presente trabajo tiene como objetivo modelar la probabilidad de supervivencia de los pasajeros del Titanic en función de sus características individuales, mediante un Modelo Lineal Generalizado con función de enlace logit. Este enfoque, permite estimar el efecto de cada variable en términos de razones de odds y evaluar posibles interacciones entre ellas.

La base de datos utilizada contiene información de 891 pasajeros. Dado que presentaba datos faltantes, se optó por eliminar las observaciones incompletas, por lo que el análisis se realizó sobre 712 observaciones. Para evaluar la capacidad predictiva del modelo, esta base se dividió en dos subconjuntos: uno de entrenamiento, con 571 observaciones, utilizado para ajustar el modelo, y uno de prueba, con las 141 restantes, reservado para evaluar su desempeño predictivo sobre datos no utilizados en el ajuste.

La variable respuesta es Survived, que indica si el pasajero sobrevivió al naufragio: toma el valor 1 si sobrevivió (SÍ) y 0 si no sobrevivió (NO). Al tratarse de una variable binaria, se asume que cada observación sigue una distribución Bernoulli, con probabilidad de éxito π, que representa la probabilidad de supervivencia.

El análisis comenzó con un estudio descriptivo de las variables, para explorar su distribución y su relación con la supervivencia. Luego se seleccionaron las variables del modelo sobre el conjunto de entrenamiento y se ajustó el modelo final con enlace logit. Se evaluó su ajuste y su capacidad predictiva sobre el conjunto de prueba. Por último, se compararon distintas funciones de enlace (logit, probit y cloglog), con el fin de identificar qué factores estuvieron más fuertemente asociados a la supervivencia.

Las variables explicativas incluidas en el análisis se describen a continuación:

- **Edad**: medida en años. Es una variable cuantitativa continua.
- **Clase**: clase del pasaje, cualitativa con 3 niveles:
  - "1": Primera clase
  - "2": Segunda clase
  - "3": Tercera clase
- **Embarcación**: puerto en el que el pasajero abordó el Titanic, categorizada en tres niveles:
  - "C": Cherburgo (Francia)
  - "Q": Queenstown (Irlanda, actual Cobh)
  - "S": Southampton (Inglaterra)
- **Sexo**: sexo del pasajero. Fue categorizada en dos niveles:
  - "Male": Masculino
  - "Female": Femenino

Análisis Descriptivo

A continuación se realiza una descripción general de las características clave de la población estudiada.

En principio, se observa que de los 712 pasajeros considerados, 424 (59,55 %) no sobrevivieron y 288 (40,45 %) sí lo hicieron, una distribución con casos suficientes en ambas categorías para estudiar los factores asociados a la supervivencia. La mayoría de los pasajeros eran hombres (63,62 %) y la mayor cantidad de pasajeros embarcaron en Southampton (77,81 %), mientras que la categoría Queenstown quedó representada por solo 28 observaciones (3,93 %), lo que podría dar estimaciones menos precisas para ese puerto. La edad presentó una distribución aproximadamente simétrica, con media de 29,64 años y mediana de 28, y una dispersión considerable (desvío estándar de 14,49 años).La clase del pasajero mostró que casi la mitad de los pasajeros viajaba en tercera clase (355 pasajeros, 49,86 %), mientras que primera y segunda clase tuvieron una participación similar y menor (184 pasajeros, 25,84 %, y 173 pasajeros, 24,30 %, respectivamente). En síntesis, la muestra es adecuada para el análisis, y las características observadas, como la composición por sexo, la edad y la clase, son variables de interés para evaluar su asociación con la supervivencia.

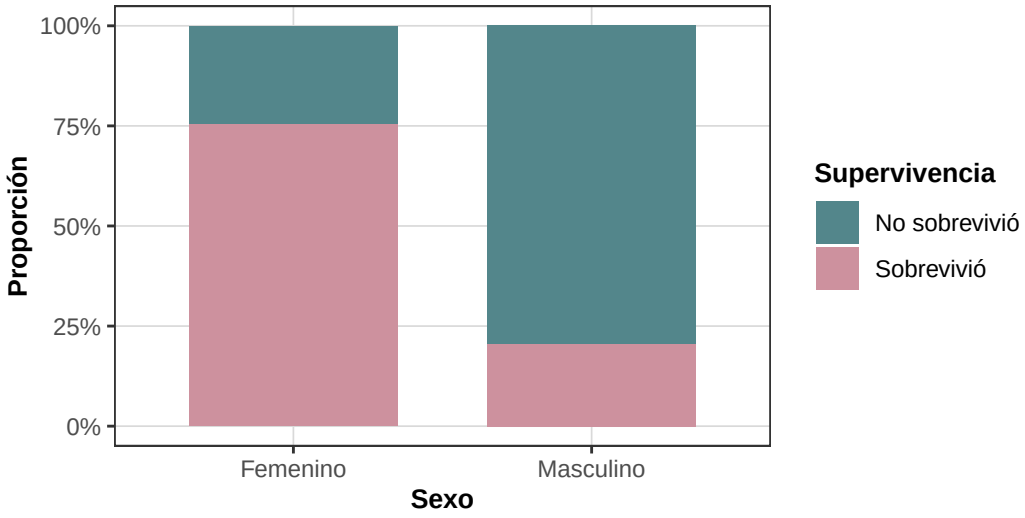


Figura 1: Proporción de pasajeros sobrevivientes según sexo

En la Figura 1, se observa que la proporción de pasajeros que sobrevivieron es más alta para aquellos con sexo femenino en comparacón a los pasajeros masculinos.

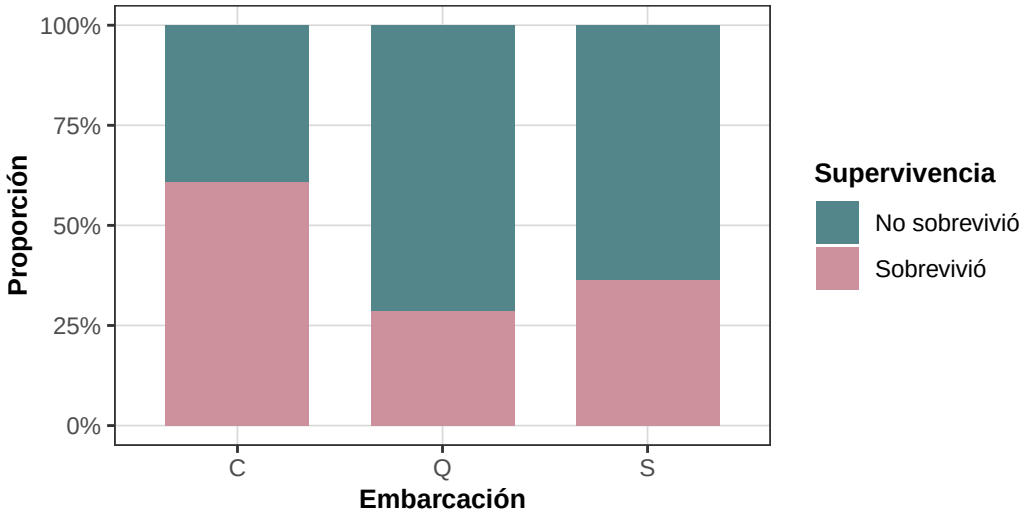


Figura 2: Proporción de pasajeros sobrevivientes según lugar de embarcación

En la Figura 2, se observa una mayor proporción de sobrevivientes entre los pasajeros que embarcaron en C (aprox. 60 %) en comparación con Q y S (aprox. 28 % y 36 %), lo que sugiere una posible asociación entre el puerto de embarque y la supervivencia.

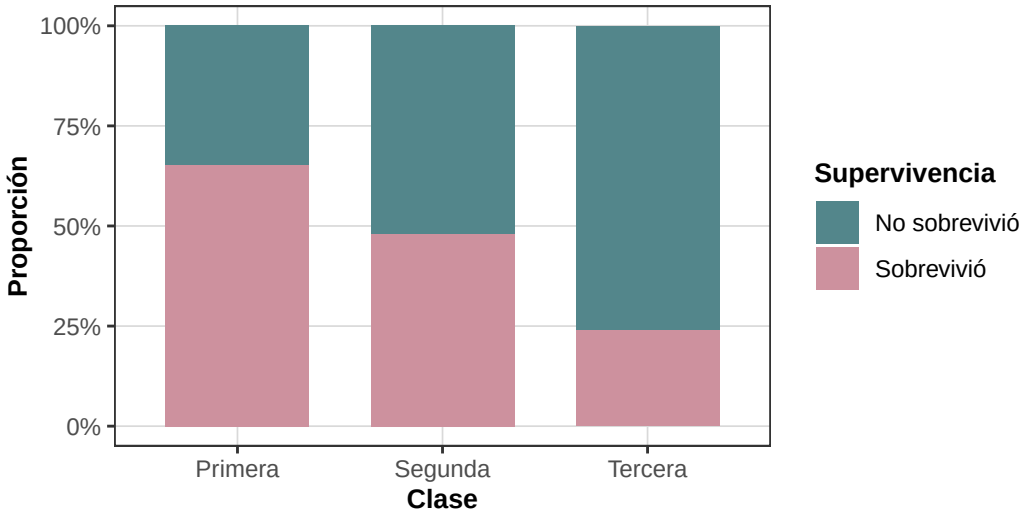


Figura 3: Proporción de pasajeros sobrevivientes según clase

En la Figura 3, se observa que, en primera clase sobrevivió aproximadamente el 65 % de los pasajeros, en segunda clase cerca del 48 % y en tercera clase solo alrededor del 24 %. Es decir, la supervivencia fue mayor en la clase más alta y menor en la más baja. Esto sugiere una asociación entre la clase y la supervivencia, por lo que esta variable resulta relevante para incluir en el análisis.

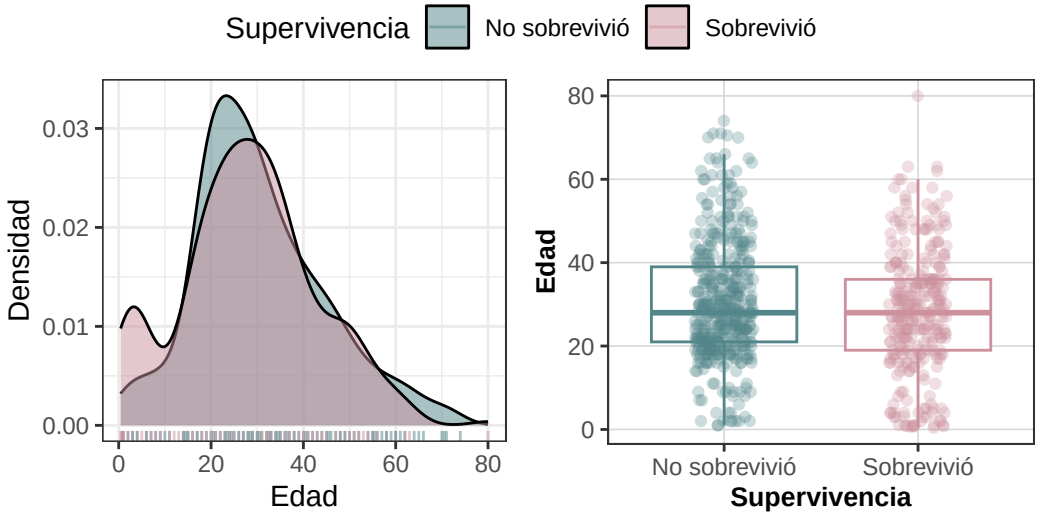


Figura 4: Distribución de la edad según supervivencia

La distribución de la edad es similar entre sobrevivientes y no sobrevivientes, con medianas casi idénticas (aprox. 28 años), por lo que la edad parece no estar fuertemente asociada a la supervivencia. Se observa, sin embargo, una mayor proporción de sobrevivientes entre los niños pequeños, y una leve mayor presencia de no sobrevivientes en edades avanzadas.

Modelado estadístico

El trabajo se realizará bajo el enfoque de modelos lineales generalizados, utilizando lo desarrollado por Nelder y Wedderburn.

Selección del modelo

Para modelar la probabilidad de supervivencia de los pasajeros del Titanic, en función de las variables explicativas sexo, edad, clase y puerto de embarque, se propuso emplear un modelo con función de enlace logit.

En primer lugar, se seleccionaron las variables explicativas consideradas relevantes para explicar la supervivencia de los pasajeros y se ajustó un modelo que incluyó sus efectos principales. A continuación, se evaluó la incorporación de interacciones de segundo orden entre dichas variables, utilizando los métodos de selección hacia adelante (forward) y hacia atrás (backward), con el criterio de información de Akaike (AIC) y la deviance de cada modelo. Ambos procedimientos condujeron al mismo modelo final, que incorpora las vaiables sexo, edad, clase y la interaccion entre sexo y clase.

Probamos linealidad de la predictora continua

Para evaluar si la relación entre la edad y el logit de la probabilidad de supervivencia podía considerarse lineal, se construyó una versión categorizada de la edad en cuatro tramos definidos por los cuartiles del conjunto de entrenamiento: $[0.42, 20], (20, 28], (28, 38]$ y $(38, 74]$. Se comparó el modelo con la edad continua contra el modelo que incorpora además la edad categorizada mediante una prueba de razón de verosimilitud, de modo que el modelo lineal quedara anidado en el ampliado. Los resultados no proporcionaron evidencia suficiente para justificar la incorporación de la edad categorizada (p-valor = 0.137). Por lo tanto, se decidió mantener la edad como variable continua en el modelo final.

Por lo tanto, el modelo seleccionado se expresa como:

$$\begin{aligned}\operatorname{logit}(\pi_i) = \ln\left(\frac{\pi_i}{1-\pi_i}\right) =& \beta_0 + \beta_1 \,\text{Sexo}_i + \beta_2 \,\text{Clase2}_i + \beta_3 \,\text{Clase3}_i + \beta_4 \,\text{Edad}_i + \\ &+ \beta_5 \,(\text{Sexo}_i \times \text{Clase2}_i) + \beta_6 \,(\text{Sexo}_i \times \text{Clase3}_i), \quad i = \overline{1, 571}\end{aligned}$$

$$\text{Sexo}_i = \begin{cases} 1 & \text{si Masculino} \\ 0 & \text{si Femenino} \end{cases}$$

$$\text{Clase2}_i = \begin{cases} 1 & \text{si Clase} = 2 \\ 0 & \text{en otro caso} \end{cases} \qquad \text{Clase3}_i = \begin{cases} 1 & \text{si Clase} = 3 \\ 0 & \text{en otro caso} \end{cases}$$

Bondad del ajuste y estimación del modelo

Se evalúa la adecuación de la función de enlace logit utilizada en el modelo aplicando el test de especificación de la función de enlace, que consiste en incorporar al modelo un término adicional cuadrático del predictor lineal estimado:

El procedimiento implica ajustar un modelo extendido que incluye esta nueva variable y comparar su ajuste con el modelo original mediante una prueba de razón de verosimilitud. En este análisis, la comparación entre ambos modelos no mostró evidencia suficiente para rechazar la adecuación del enlace logit, por lo que se considera apropiado mantenerlo en el modelo final ($p - value = 0.14$).

Se compararon las tres funciones de enlace (logit, probit y cloglog) ajustando cada una con el mismo predictor lineal. El menor valor del criterio de información de Akaike correspondió al enlace logit. Este resultado, junto con que el test de adecuación del enlace no rechazó el logit (p-valor = 0.14), respalda su elección. Además, el enlace logit permite interpretar los efectos en términos de razones de odds, por lo que se continúa el análisis con este modelo.

Además, para evaluar la bondad de ajuste del modelo, se aplicó la prueba de Hosmer y Lemeshow. Esta prueba compara las frecuencias observadas y esperadas del evento de interés en grupos formados a partir de los valores predichos por el modelo y dado el tamaño muestral disponible.

La prueba de Hosmer-Lemeshow con 12 grupos (estadístico = 17,11; gl = 10; p = 0,072) no rechaza la hipótesis de buen ajuste. Cabe aclarar que el resultado es sensible al número de grupos: con 8 y 10 grupos el p-valor fue menor a 0,05. Por lo tanto, no hay evidencia concluyente de falta de ajuste, aunque podrían existir desvíos leves.

Considerando los resultados del estudio del modelo a través de los diferentes tests de hipótesis, el modelo estimado es el siguiente:

$$\begin{aligned}\operatorname{logit}(\widehat{\pi}_i) = \ln\left(\frac{\widehat{\pi}_i}{1-\widehat{\pi}_i}\right) =& 4.85 - 3.45\,\text{Sexo}_i - 1.21\,\text{Clase2}_i - 4.14\,\text{Clase3}_i - 0.045\,\text{Edad}_i - \\ &- 0.90\,(\text{Sexo}_i \times \text{Clase2}_i) + 2.06\,(\text{Sexo}_i \times \text{Clase3}_i), \quad i = \overline{1,571}\end{aligned}$$

Análisis de residuos

El análisis de residuos permite evaluar la adecuación del modelo ajustado, tanto en lo que respecta a la componente sistemática como a la aleatoria.

Con el objetivo de analizar la estructura del modelo, se construyó el gráfico de los residuos cuantil frente a las probabilidades estimadas bajo el enlace logit.

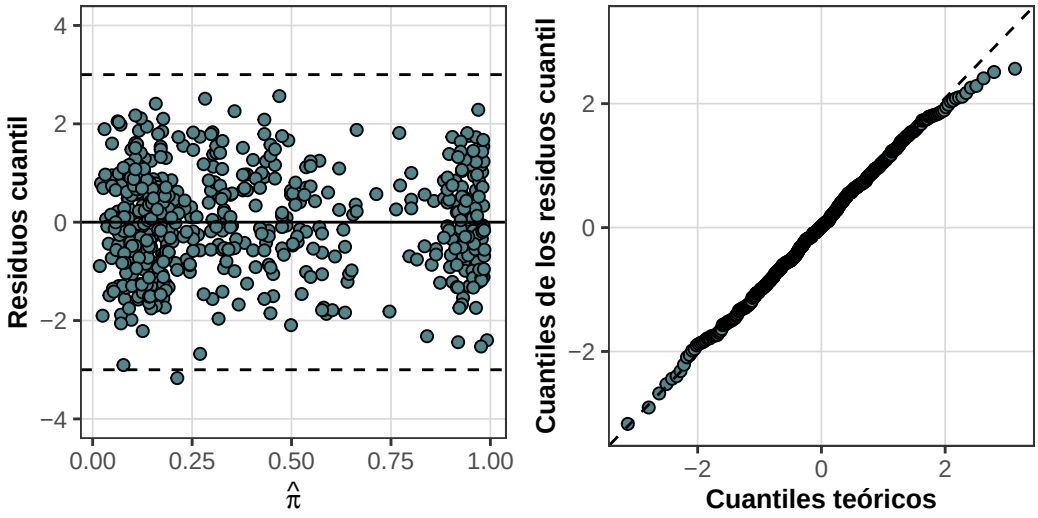


Figura 5: Análisis de residuos

En el gráfico de residuos cuantil contra las probabilidades estimadas (Figura 5) se observa que los residuos se distribuyen aproximadamente alrededor de cero, sin un patrón sistemático definido. Aunque hay una mayor concentración de observaciones en las probabilidades estimadas más bajas, no se identifican tendencias claras que indiquen problemas importantes de ajuste, lo que sugiere que la función de enlace logit es adecuada. Además, para verificar la distribución supuesta de los errores, se empleó el gráfico probabilístico normal de los residuos cuantil (Figura 5), donde los puntos se alinean adecuadamente con la línea de referencia, con leves desviaciones en los extremos. En conjunto, no se evidencian desvíos sistemáticos importantes, por lo que el modelo presenta un ajuste globalmente satisfactorio.

Estudio de la capacidad predictiva del modelo

La capacidad predictiva del modelo se evaluó sobre el conjunto de validación, es decir, sobre pasajeros que no participaron en la estimación de los parámetros, de modo de obtener una medida de desempeño que no esté sesgada por el ajuste.

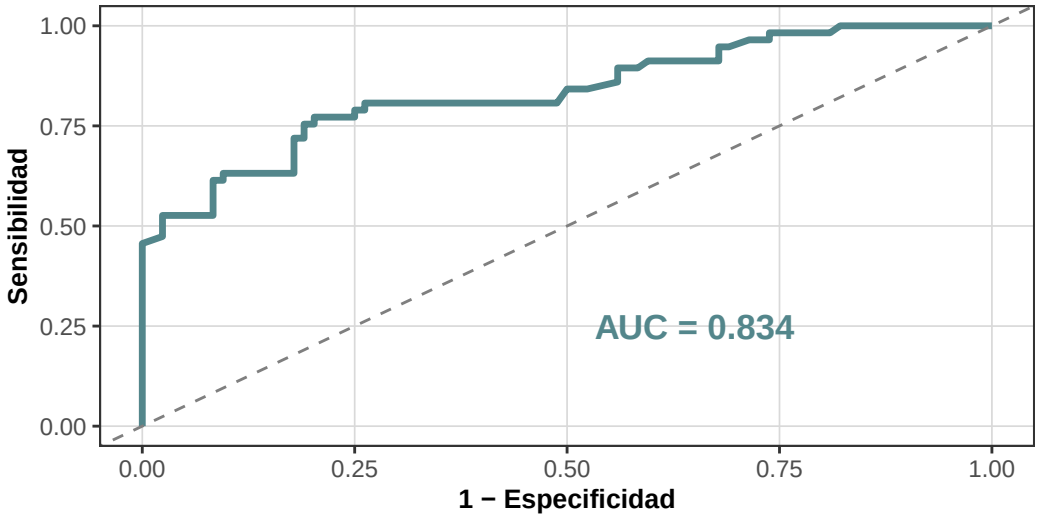


Figura 6: Curva ROC en el conjunto de validación

Con las probabilidades de supervivencia estimadas para esas observaciones, se construyó la curva ROC (Figura 6), que muestra cómo varían la sensibilidad (tasa de verdaderos positivos) y la tasa de falsos positivos (1 - especificidad) al modificar el punto de corte de clasificación. Complementariamente, se calculó el área bajo la curva (AUC) como resumen de la capacidad discriminante del modelo, que fue de 0,834.

El punto de corte de clasificación se determinó con el conjunto de entrenamiento y resultó de 0,270, valor que maximiza la suma de la sensibilidad y la especificidad (índice de Youden). Con este umbral aplicado al conjunto de validación se obtuvo la siguiente matriz de confusión:

Tabla 1: Matriz de confusión en el conjunto de validación

	Observado	
	No sobrevivió	Sobrevivió
Predicho: No sobrevivió	66	13
Predicho: Sobrevivió	18	44

El modelo logró clasificar correctamente al 78 % de las observaciones del conjunto de validación, con una sensibilidad del 77,2 % (proporción de sobrevivientes correctamente identificados) y una especificidad del 78,6 % (proporción de no sobrevivientes correctamente clasificados).

Resultados

En esta sección se presentan los principales hallazgos obtenidos a partir del modelo final ajustado. En primer lugar, se exponen las razones de odds estimadas para cada variable

significativa, seguidas por la representación gráfica de las mismas.

Razones de odds

Las razones de odds permiten cuantificar la variación en la probabilidad de sobrevivir ante cambios en las variables explicativas, manteniendo constantes las demás condiciones.

Tabla 2: Razones de odds e intervalos de confianza de nivel 0,95 (Wald)

Contraste	RO	IC 95 %
Edad (X + 5 vs. X)	0.799	(0.728; 0.877)
Sexo (masc. vs. fem.) en 1ª clase	0.032	(0.009; 0.111)
Sexo (masc. vs. fem.) en 2ª clase	0.013	(0.004; 0.04)
Sexo (masc. vs. fem.) en 3ª clase	0.248	(0.135; 0.456)
2ª vs. 1ª clase en mujeres	0.297	(0.07; 1.269)
3ª vs. 1ª clase en mujeres	0.016	(0.004; 0.059)
2ª vs. 1ª clase en hombres	0.122	(0.05; 0.296)
3ª vs. 1ª clase en hombres	0.124	(0.063; 0.244)

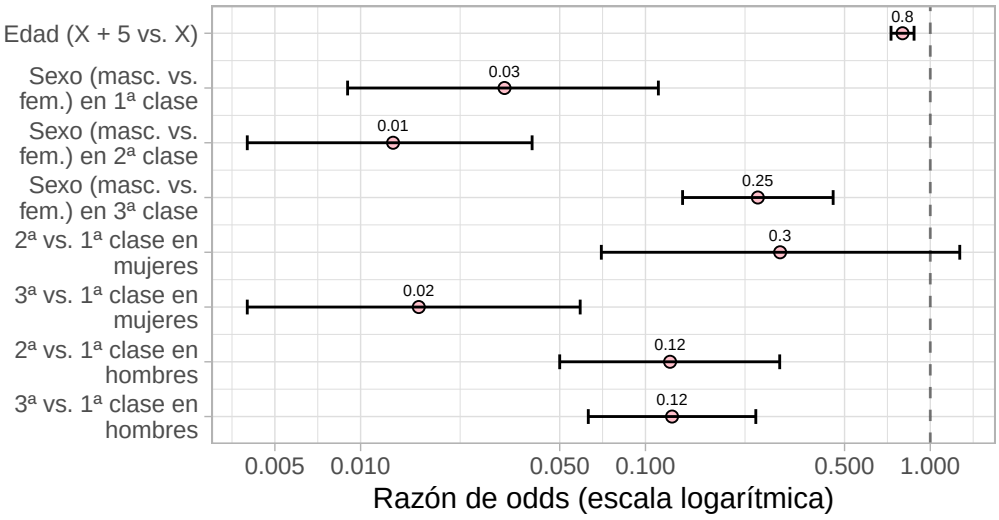


Figura 7: Forest plot de Razones de odds (cambios en edad por 5 años)

De la Tabla 2 y la Figura 7 se extrae que:

- La chance de sobrevivir de una persona de determinada edad es entre un 12,3 % y un 27,2 % menor que la de una persona cinco años menor, para el mismo sexo y la misma clase.

- Para los pasajeros de 1° clase, la chance de sobrevivir de los hombres es entre un 88,9 % y un 99,1 % menor que la de las mujeres, para la misma edad.
- Para los pasajeros de 2° clase, la chance de sobrevivir de los hombres es entre un 96 % y un 99,6 % menor que la de las mujeres, para la misma edad.
- Para los pasajeros de 3° clase, la chance de sobrevivir de los hombres es entre un 54,4 % y un 86,5 % menor que la de las mujeres, para la misma edad.
- Para los pasajeros de género femenino, la chance de sobrevivir estando en 3° clase es entre un 94,1 % y un 99,6 % menor que las que se encuentran en 1° clase, para la misma edad.
- Para los pasajeros de género masculino, la chance de sobrevivir estando en 2° clase es entre un 70,4 % y un 95 % menor que los que se encuentran en 1° clase, para la misma edad.
- Para los pasajeros de género masculino, la chance de sobrevivir estando en 3° clase es entre un 75,6 % y un 93,7 % menor que la de los hombres de 1° clase, para la misma edad.

Conclusión

El presente trabajo permitió ajustar y evaluar un modelo lineal generalizado con enlace logit para estudiar los factores asociados a la supervivencia de los pasajeros. A través de un proceso de selección, diagnóstico y validación, se obtuvo un modelo final con el sexo, la edad y la clase como variables explicativas, incluyendo la interacción entre sexo y clase.

El análisis evidenció que el sexo, la clase y la edad contribuyen a explicar la probabilidad de sobrevivir. Los hombres tuvieron una chance de sobrevivir mucho menor que las mujeres en las tres clases, aunque la brecha fue menor en tercera clase. Viajar en una clase inferior también se asoció con una menor chance de supervivencia: en las mujeres la diferencia apareció en tercera clase, mientras que en los hombres ya se observó en segunda y tercera clase respecto de la primera. Además, por cada cinco años más de edad, la chance de sobrevivir disminuyó, para el mismo sexo y la misma clase. La validación del modelo, mediante la curva ROC y la matriz de confusión, mostró una capacidad predictiva adecuada, con una exactitud cercana al 78 %, lo que confirma su utilidad para clasificar a los pasajeros según su supervivencia.