UNIVERSIDAD NACIONAL
DE ROSARIO
FACULTAD DE CIENCIAS
ECONÓMICAS Y ESTADÍSTICA



UNR

Trabajo Práctico de Modelos Lineales Generalizados

Integrantes:
Cañizares María Inés
Zame, Lisbeth

Licenciatura en Estadística

Año 2026

Introducción

El hundimiento del RMS Titanic, ocurrido en 1912 durante su viaje inaugural, es una de las tragedias marítimas más recordadas de la historia. Considerado el mayor transatlántico de su época y casi insumergible, su naufragio causó la muerte de más de 1.500 de las aproximadamente 2.200 personas a bordo y dejó en evidencia graves falencias de seguridad, como la escasez de botes salvavidas. El suceso provocó una conmoción mundial e impulsó cambios en la normativa internacional. Los datos de sus pasajeros permiten, además, estudiar si la supervivencia estuvo asociada a características individuales como el sexo, la edad, la tarifa abonada o el puerto de embarque, y contrastar con evidencia empírica la norma de "mujeres y niños primero".

En este trabajo se busca identificar los factores con mayor influencia en la probabilidad de supervivencia de los pasajeros, mediante un Modelo Lineal Generalizado sobre la base de datos del Titanic construida a partir de registros históricos reales.

Material y métodos

En este contexto, el presente trabajo tiene como objetivo modelar la probabilidad de supervivencia de los pasajeros del Titanic en función de sus características individuales, mediante un Modelo Lineal Generalizado con función de enlace logit. Este enfoque, permite estimar el efecto de cada variable en términos de razones de odds y evaluar posibles interacciones entre ellas.

La base de datos utilizada contiene información de 891 pasajeros. Dado que presentaba datos faltantes, se optó por eliminar las observaciones incompletas, por lo que el análisis se realizó sobre 712 observaciones. Para evaluar la capacidad predictiva del modelo, esta base se dividió en dos subconjuntos: uno de entrenamiento, con 571 observaciones, utilizado para ajustar el modelo, y uno de prueba, con las 141 restantes, reservado para evaluar su desempeño predictivo sobre datos no utilizados en el ajuste.

La variable respuesta es Survived, que indica si el pasajero sobrevivió al naufragio: toma el valor 1 si sobrevivió (SÍ) y 0 si no sobrevivió (NO). Al tratarse de una variable binaria, se asume que cada observación sigue una distribución Bernoulli.

El análisis comenzó con un estudio descriptivo de las variables, para explorar su distribución y su relación con la supervivencia. Luego se seleccionaron las variables del modelo sobre el conjunto de entrenamiento y se ajustó el modelo final con enlace logit. Se evaluó su ajuste y su capacidad predictiva sobre el conjunto de prueba. Por último, se compararon distintas funciones de enlace (logit, probit y cloglog), con el fin de identificar qué factores estuvieron más fuertemente asociados a la supervivencia.

Las variables explicativas incluidas en el análisis se describen a continuación:

- **Edad**: medida en años. Es una variable cuantitativa continua.

- **Tarifa**: precio del pasaje abonado por el pasajero, medida en libras esterlinas (£). Es una variable cuantitativa continua.
- **Embarcación**: puerto en el que el pasajero abordó el Titanic, categorizada en tres niveles:
  - "C": Cherburgo (Francia)
  - "Q": Queenstown (Irlanda, actual Cobh)
  - "S": Southampton (Inglaterra)
- **Sexo**: sexo del pasajero. Fue categorizada en dos niveles:
  - "Male": Masculino
  - "female": Femenino

Análisis Descriptivo

A continuación se presenta una visión general de las características clave de la población estudiada.

Tabla 1: Frecuencias absolutas y relativas de supervivencia

Sobrevivió	Frecuencia	Porcentaje (%)
No	424	59.55
Sí	288	40.45
Total	712	100.00

{r, eval=FALSE} # # resumen general de variables # skim(datos) #

Tabla 2: Frecuencias absolutas y relativas de sexo

Sexo	Frecuencia	Porcentaje (%)
Femenino	259	36.38
Masculino	453	63.62
Total	712	100

Tabla 3: Frecuencias absolutas y relativas de Embarcación

Embarcación	Frecuencia	Porcentaje (%)
C	130	18.26
Q	28	3.93
S	554	77.81
Total	712	100

Tabla 4: Estadísticas descriptivas de la variable edad

Variable	Media	Mediana	DE	Mínimo	Máximo
edad	29.64	28	14.49	0.42	80

Tabla 5: Estadísticas descriptivas de la variable edad

Variable	Media	Mediana	DE	Mínimo	Máximo
tarifa	34.57	15.64585	52.94	0	512.3292

FALTAN CONCLUSIONES DE TABLAS DESPUES DE REPRODUCIR

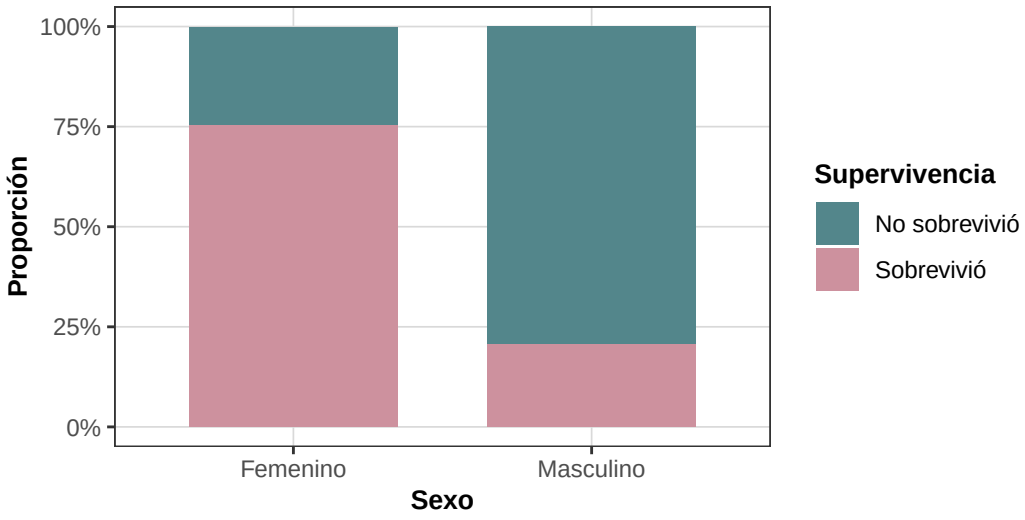


Figura 1: Proporción de pasajeros sobrevivientes según sexo

Se observa que la proporción de pasajeros que sobrevivieron es más alta para aquellos con sexo femenino en comparacón a los pasajeros masculinos.

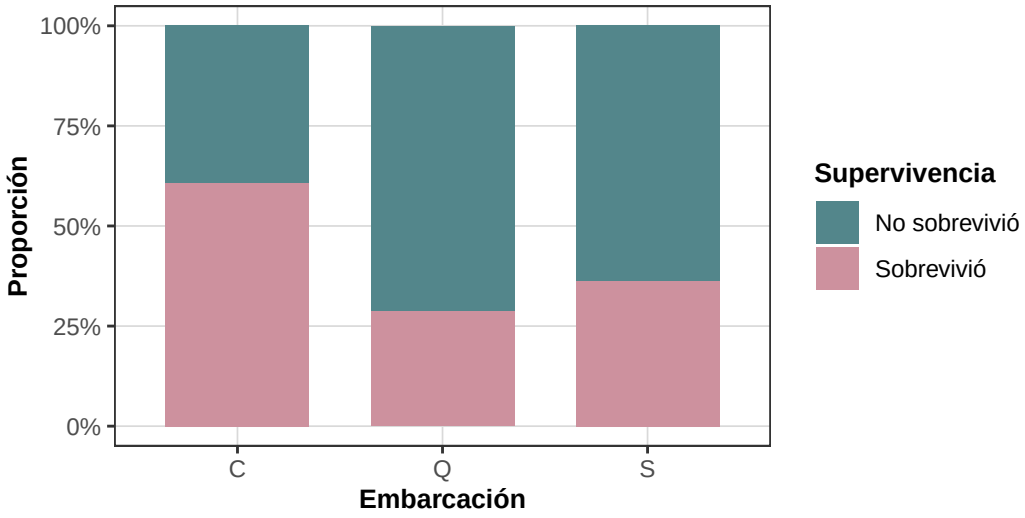


Figura 2: Proporción de pasajeros sobrevivientes según lugar de embarcación

Se observa una mayor proporción de sobrevivientes entre los pasajeros que embarcaron en C (aprox. 60 %) en comparación con Q y S (aprox. 28 % y 36 %), lo que sugiere una posible asociación entre el puerto de embarque y la supervivencia.

Graficos de la variable edad

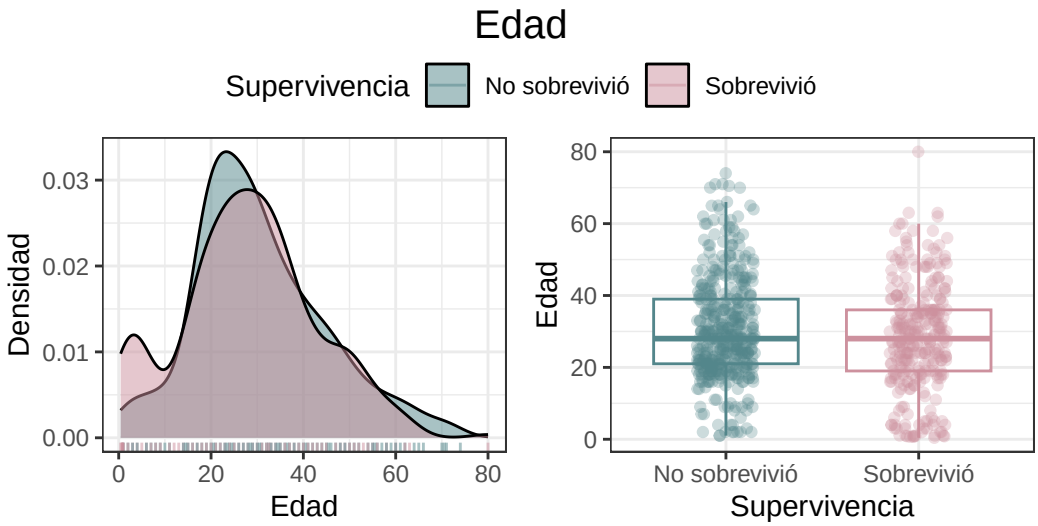


Figura 3: Distribución de la edad según supervivencia

La distribución de la edad es similar entre sobrevivientes y no sobrevivientes, con medianas casi idénticas (aprox. 28 años), por lo que la edad parece no estar fuertemente asociada a la supervivencia. Se observa, sin embargo, una mayor proporción de sobrevivientes entre los niños pequeños, y una leve mayor presencia de no sobrevivientes en edades avanzadas.

GRaficos de la variable Tarifa

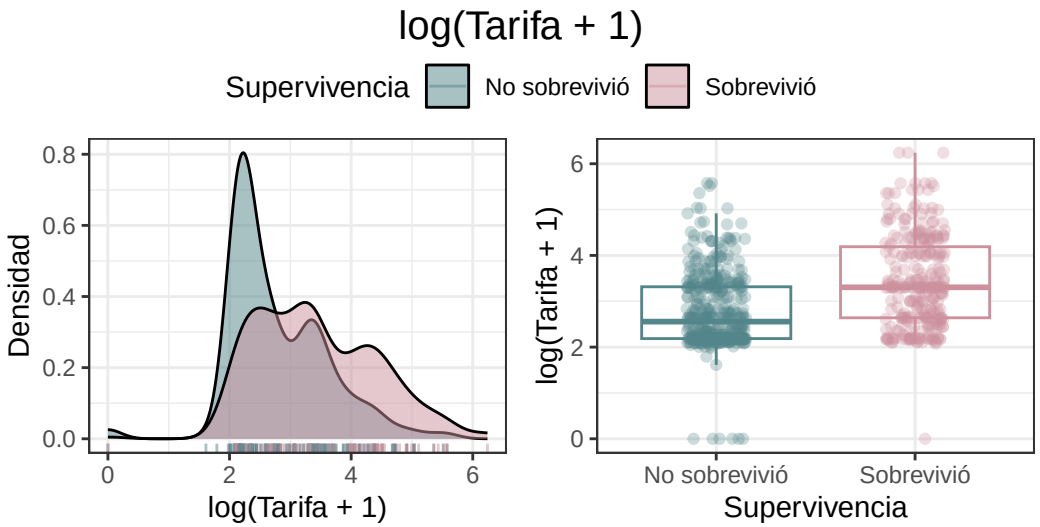


Figura 4: Distribución de la log(Tarifa) según supervivencia

La tarifa pagada parece estar asociada a la supervivencia: los pasajeros que sobrevivieron presentan en general tarifas más altas (mediana de log(Tarifa + 1) mayor) que quienes no sobrevivieron, que se concentran en tarifas bajas. Esto sugiere que la tarifa podría ser un predictor relevante de la supervivencia.

Modelado estadístico

El trabajo se realizará bajo el enfoque de modelos lineales generalizados, utilizando lo desarrollado por Nelder y Wedderburn.

Selección del modelo

Para modelar la probabilidad de supervivencia de los pasajeros del Titanic, en función de las variables explicativas sexo, edad, tarifa del pasaje y puerto de embarque, se propuso emplear un modelo con función de enlace logit.

En primer lugar, se seleccionaron las variables explicativas consideradas relevantes para explicar la supervivencia de los pasajeros y se ajustó un modelo que incluyó sus efectos principales. A continuación, se evaluó la incorporación de interacciones de segundo orden entre dichas variables, utilizando los métodos de selección hacia adelante (forward) y hacia atrás (backward), con el criterio de información de Akaike (AIC) y la deviance de cada modelo. Ambos procedimientos condujeron al mismo modelo final, que incorpora las interacciones entre sexo y edad, y entre edad y tarifa del pasaje.

Probamos linealidad de la predictoras continuas

Con el objetivo de evaluar si la relación entre la edad y el logit de la probabilidad de supervivencia podía considerarse lineal, se compararon dos modelos alternativos.

En primer lugar, se construyó un modelo que incorpora la variable edad como ordinal, dividiendo su rango en cinco categorías según los cuantiles 0.2, 0.4, 0.6 y 0.8. Posteriormente, se ajustó un segundo modelo en el que la edad se representó mediante variables indicadoras (dummies), permitiendo una relación no necesariamente lineal con la respuesta.

El modelo ordinal se puede expresar como:

$$\text{logit}(\pi_i) = \beta_0 + \beta_1 \,\text{Sexo}_i + \beta_2 \,\text{logTarifa}_i + \beta_3 \,\text{EmbarcacionQ}_i + \beta_4 \,\text{EmbarcacionS}_i + \beta_5 \,\text{Edad}_i + \beta_6 \,(\text{Sexo}_i \times \text{Edad}_i) +$$

Mientras que el modelo con variables indicadoras se define como:

$$\begin{aligned}\text{logit}(\pi_i) = {} & \beta_0 + \beta_1 \,\text{Sexo}_i + \beta_2 \,\text{logTarifa}_i + \beta_3 \,\text{EmbarcacionQ}_i + \beta_4 \,\text{EmbarcacionS}_i \\ & + \beta_5 \,\text{Edad2}_i + \beta_6 \,\text{Edad3}_i + \beta_7 \,\text{Edad4}_i + \beta_8 \,\text{Edad5}_i \\ & + \beta_9 \,(\text{Sexo}_i \times \text{Edad2}_i) + \beta_{10} \,(\text{Sexo}_i \times \text{Edad3}_i) + \beta_{11} \,(\text{Sexo}_i \times \text{Edad4}_i) + \beta_{12} \,(\text{Sexo}_i \times \text{Edad5}_i) \\ & + \beta_{13} \,(\text{logTarifa}_i \times \text{Edad2}_i) + \beta_{14} \,(\text{logTarifa}_i \times \text{Edad3}_i) + \beta_{15} \,(\text{logTarifa}_i \times \text{Edad4}_i) + \beta_{16} \,(\text{logTarifa}_i\end{aligned}$$

Finalmente, se evaluó si la incorporación de esta última variable aportaba una mejora significativa al modelo original mediante una prueba de razón de verosimilitudes.

Los resultados no proporcionaron evidencia suficiente para justificar la incorporación de la edad categorizada ($p-value = 0.19$). Por lo tanto, se decidió mantener la edad como variable continua en el modelo final.

Adicionalmente, dado que se cuenta con otra variable continua clave como el logaritmo de la tarifa (logTarifa), se procedió a evaluar de forma análoga si su relación con el logit de la probabilidad de supervivencia podía considerarse lineal mediante la comparación de modelos alternativos.

En primer lugar, se construyó un modelo que incorpora la variable logTarifa como ordinal, dividiendo su rango en cinco categorías según los cuantiles 0.2, 0.4, 0.6 y 0.8. Posteriormente, se ajustó un segundo modelo en el que dicha variable se representó mediante variables indicadoras (dummies), permitiendo capturar una relación no necesariamente lineal con la respuesta.

El modelo ordinal se puede expresar como:

$$\text{logit}(\pi_i) = \beta_0 + \beta_1 \,\text{Sexo}_i + \beta_2 \,\text{logTarifa}_i + \beta_3 \,\text{EmbarcacionQ}_i + \beta_4 \,\text{EmbarcacionS}_i + \beta_5 \,\text{Edad}_i + \beta_6 \,(\text{Sexo}_i \times \text{Edad}_i) +$$

Mientras que el modelo con variables indicadoras se define como:

$$ logit(_i) = _0 + _1,Sexo_i + _2,Edad_i + _3,EmbarcacionQ_i + _4,EmbarcacionS_i + _5,logTarifa2_i + _6,logTarifa3_i + _7,logTarifa4_i + _8,logTarifa5_i + _9, (Sexo_i ×Edad_i) + _10,(logTarifa2_i ×Edad_i) + _11,(logTarifa3_i ×Edad_i) + _12, (logTarifa4_i ×Edad_i) + _13, (logTarifa5_i ×Edad_i)

$$ Los resultados no proporcionaron evidencia suficiente para justificar la incorporación de la tarifa categorizada de forma no lineal ($p - value = 0.56$). Por lo tanto, se decidió mantener logTarifa como variable continua en el modelo final.

Por lo tanto, el modelo seleccionado se expresa como:

$$\text{logit}(\pi_i) = \ln\left(\frac{\pi_i}{1-\pi_i}\right) = \beta_0 + \beta_1\,\text{Sexo}_i + \beta_2\,\text{logTarifa}_i + \beta_3\,\text{EmbarcacionQ}_i + \beta_4\,\text{EmbarcacionS}_i + \beta_5\,\text{Edad}_i + \beta_6\,(\text{Se}$$

```
Call:
glm(formula = Survived ~ Sex + logFare + Embarked + Age + Sex:Age +
    logFare:Age, family = binomial("logit"), data = train)

Coefficients:
              Estimate Std. Error z value Pr(>|z|)
(Intercept)   -0.791618   1.035182  -0.765  0.44444
Sexfemale      0.932122   0.485909   1.918  0.05507 .
logFare        0.123888   0.298546   0.415  0.67816
EmbarkedC      0.617034   0.286326   2.155  0.03116 *
EmbarkedQ     -0.500167   0.598807  -0.835  0.40356
Age           -0.094543   0.036600  -2.583  0.00979 **
Sexfemale:Age  0.050158   0.016786   2.988  0.00281 **
logFare:Age    0.018863   0.009998   1.887  0.05922 .
---
Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

(Dispersion parameter for binomial family taken to be 1)

    Null deviance: 770.64  on 570  degrees of freedom
Residual deviance: 541.82  on 563  degrees of freedom
AIC: 557.82

Number of Fisher Scoring iterations: 5
```

donde:

- $\text{Sexo}_i = \begin{cases} 1 & \text{si Masculino} \\ 0 & \text{si Femenino} \end{cases}$

- $\text{EmbarcaciónQ}_i = \begin{cases} 1 & \text{si Embarcación} = \text{Q} \\ 0 & \text{si en otro caso} \end{cases}$
- $\text{EmbarcaciónS}_i = \begin{cases} 1 & \text{si Embarcación} = \text{S} \\ 0 & \text{si en otro caso} \end{cases}$

Bondad del ajuste y estimación del modelo

```
Analysis of Deviance Table

Model 1: Survived ~ Sex + logFare + Embarked + Age + Sex:Age + logFare:Age
Model 2: Survived ~ Sex + logFare + Embarked + Age + eta2 + Sex:Age +
    logFare:Age
  Resid. Df Resid. Dev Df Deviance Pr(>Chi)
1       563     541.82
2       562     539.36  1   2.4603   0.1168
```

Se evalúa la adecuación de la función de enlace logit utilizada en el modelo aplicando el test de especificación de la función de enlace, que consiste en incorporar al modelo un término adicional cuadrático del predictor lineal estimado:

$M1)$ $\text{logit}(\pi_i) = \beta_0 + \beta_1 \,\text{Sexo}_i + \beta_2 \,\text{logTarifa}_i + \beta_3 \,\text{EmbarcacionQ}_i + \beta_4 \,\text{EmbarcacionS}_i + \beta_5 \,\text{Edad}_i + \beta_6 \,(\text{Sexo}$

$M2)$ $\text{logit}(\pi_i) = \beta_0 + \beta_1 \,\text{Sexo}_i + \beta_2 \,\text{logTarifa}_i + \beta_3 \,\text{EmbarcacionQ}_i + \beta_4 \,\text{EmbarcacionS}_i + \beta_5 \,\text{Edad}_i + \beta_6 \,(\text{Sexo}$

El procedimiento implica ajustar un modelo extendido que incluye esta nueva variable y comparar su ajuste con el modelo original mediante una prueba de razón de verosimilitud. En este análisis, la comparación entre ambos modelos no mostró evidencia suficiente para rechazar la adecuación del enlace logit, por lo que se considera apropiado mantenerlo en el modelo final ($p - value = 0.12$).

```
   The Hosmer-Lemeshow goodness-of-fit test

 Group Size Observed  Expected
     1   57        5  3.150576
     2   57        9  6.476041
     3   57        5  8.592194
     4   57        8 10.209854
     5   57       13 13.473276
     6   57       25 20.596549
     7   58       32 32.895530
     8   57       35 38.546529
     9   57       45 44.550668
```

```
    10   57       54 52.508783

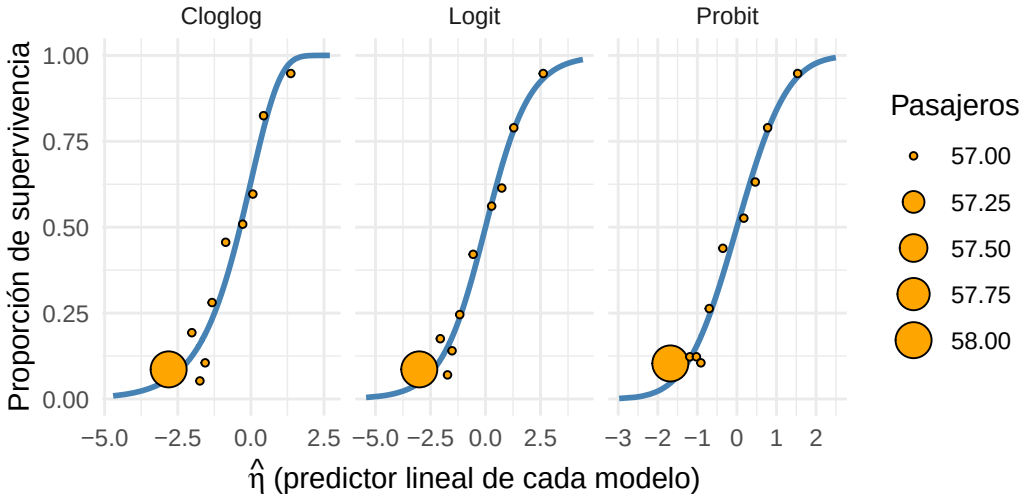
         Statistic =  7.72829
degrees of freedom =  8
           p-value =  0.46045
```

Además, para evaluar la bondad de ajuste del modelo, se aplicó la prueba de Hosmer y Lemeshow. Esta prueba compara las frecuencias observadas y esperadas del evento de interés en grupos formados a partir de los valores predichos por el modelo y dado el tamaño muestral disponible, se optó por dividir las observaciones en 10 grupos de igual tamaño según los valores de probabilidad predicha. Finalmente, se concluye que el modelo presenta un ajuste adecuado a los datos ($p - value = 0.46$).

Considerando los resultados del estudio del modelo a través de los diferentes tests de hipótesis, el ajuste realizado es el siguiente:

$$\text{logit}(\hat{\pi}_i) = \ln\left(\frac{\hat{\pi}_i}{1-\hat{\pi}_i}\right) = 0.76 - 0.93\,\text{Sexo}_i + 0.12\,\text{logTarifa}_i - 1.12\,\text{EmbarcacionQ}_i - 0.62\,\text{EmbarcacionS}_i - 0.045\,\text{Ed}$$

```
             df      AIC
modelo_final  8 557.8219
m_probit      8 557.9927
m_cloglog     8 554.4901
```



Análisis de residuos

El análisis de residuos permite evaluar la adecuación del modelo ajustado, tanto en lo que respecta a la componente sistemática como a la aleatoria.

Con el objetivo de analizar la estructura del modelo, se construyó el gráfico de los residuos cuantil frente a las probabilidades estimadas bajo el enlace logit.

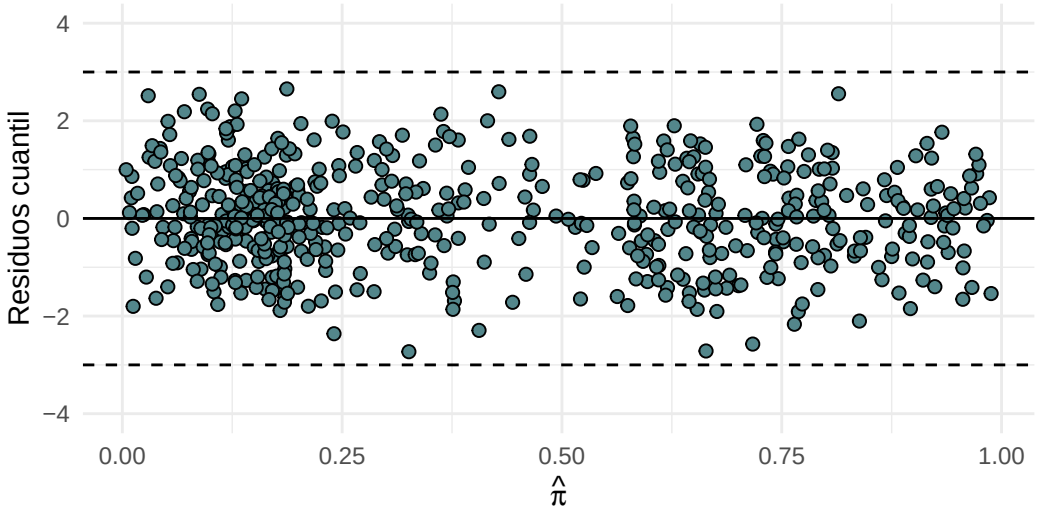


Figura 5: Gráfico de residuos cuantil vs. las probabilidades estimadas

En este gráfico se observa que los residuos se distribuyen aproximadamente alrededor de cero, sin evidenciar un patrón sistemático definido. Si bien se observa una mayor concentración de observaciones en el rango de probabilidades estimadas más bajas, no se identifican tendencias claras que indiquen problemas importantes de ajuste. Esto sugiere que la función de enlace logit es adecuada y que el modelo logra capturar correctamente la relación entre las variables explicativas y la probabilidad de sobrevivir.

Además, para verificar la adecuación de la distribución supuesta de los errores, se empleó un gráfico QQ de los residuos cuantil.

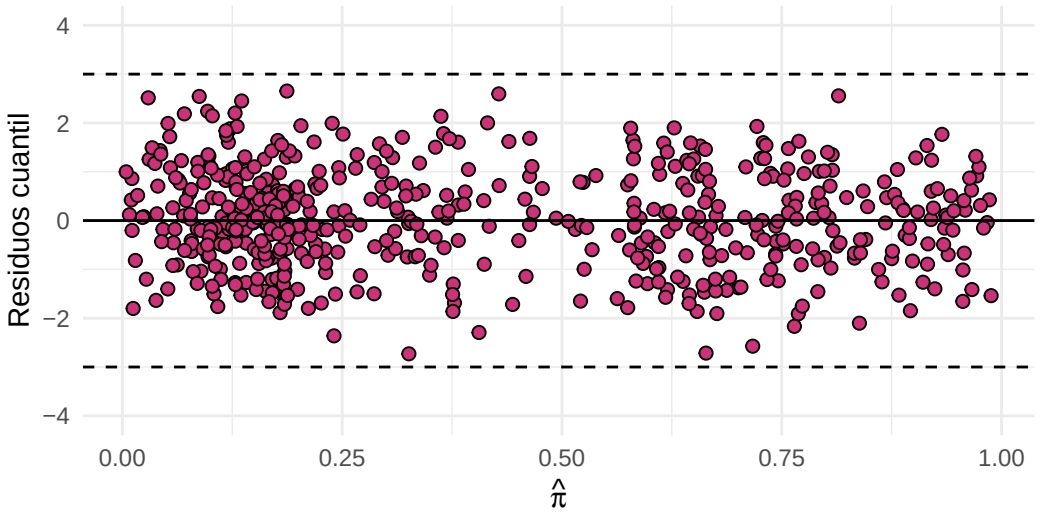


Figura 6: Gráfico de residuos cuantil vs. las probabilidades estimadas

ESTE A CHEQUEAR

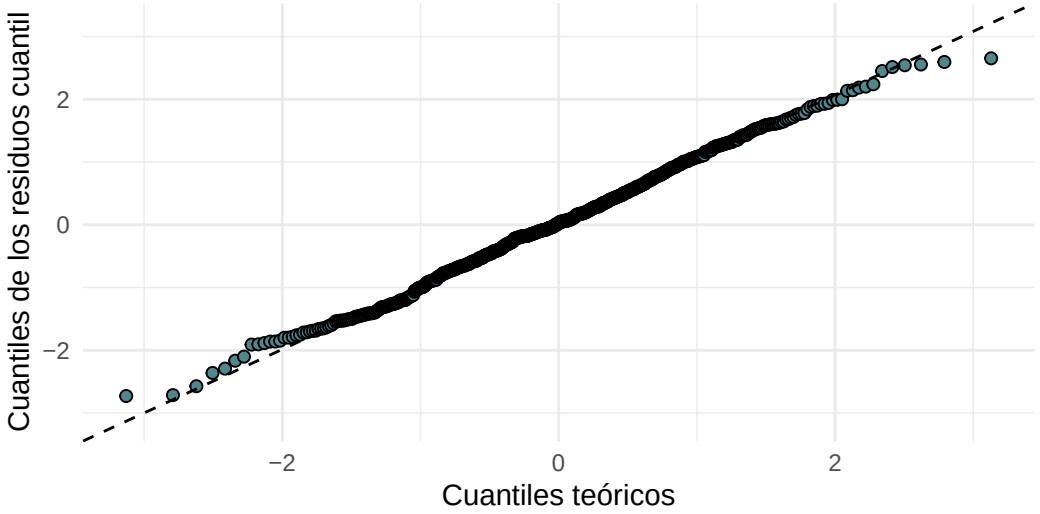


Figura 7: Gráfico probabilístico normal con residuos cuantil

En dicho gráfico se observa que los puntos se alinean de manera adecuada a lo largo de la línea de referencia, con leves dispersiones concentradas en los extremos. Por lo tanto, no se evidencian desvíos sistemáticos importantes respecto a la distribución teórica esperada, lo que sugiere un ajuste globalmente satisfactorio del modelo.

Estudio de la capacidad predictiva del modelo

La capacidad predictiva del modelo se evaluó sobre el conjunto de validación, es decir, sobre pasajeros que no participaron en la estimación de los parámetros, de modo de obtener una medida de desempeño que no esté sesgada por el ajuste. Con las probabilidades de supervivencia estimadas para esas observaciones, se construyó la curva ROC, que muestra cómo varían la sensibilidad (tasa de verdaderos positivos) y la tasa de falsos positivos (1 - especificidad) al modificar el punto de corte de clasificación. Esta curva permite analizar el equilibrio entre ambos tipos de acierto y error, y es una herramienta útil para elegir un umbral de clasificación adecuado. Complementariamente, se calculó el área bajo la curva (AUC) como resumen de la capacidad discriminante del modelo.

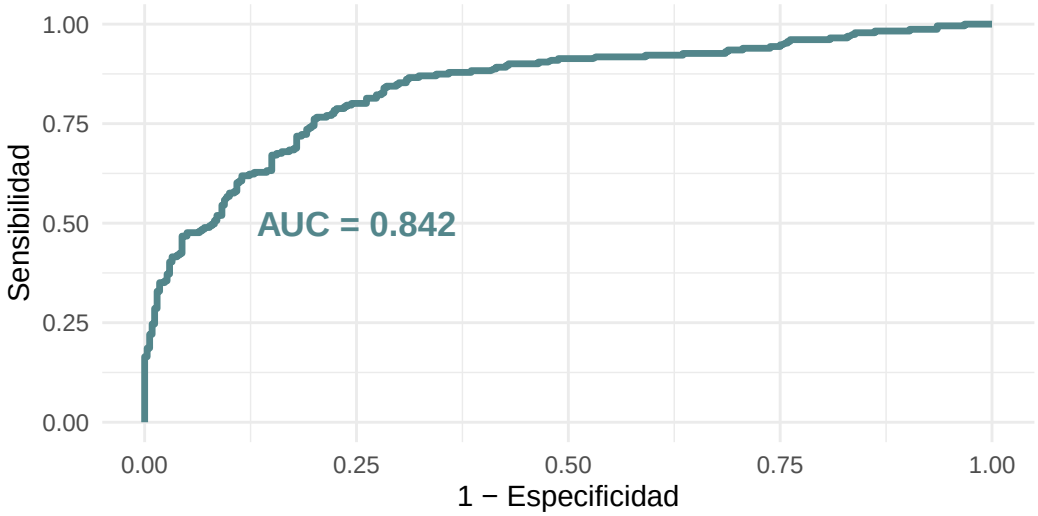


Figura 8: Curva ROC

```
[1] 0.3798941
```

El punto de corte seleccionado fue de 0.842, correspondiente al valor que maximiza simultáneamente la sensibilidad y la especificidad del modelo. Con este umbral se obtuvo la siguiente matriz de confusión, que resume el desempeño del modelo en la clasificación de los casos:

Predicho / Observado	**No Sobrevivió**	**Sobrevivió**
No Sobrevivió	69	13
Sobrevivió	15	44

El modelo logró clasificar correctamente al 80 % de las observaciones del conjunto de validación, con una sensibilidad del 77 % (proporción de sobrevivientes correctamente identificados) y una especificidad del 82.1 % (proporción de no sobrevivientes correctamente clasificados).

Resultados

En esta sección se presentan los principales hallazgos obtenidos a partir del modelo final ajustado. En primer lugar, se exponen las razones de odds estimadas para cada variable significativa, seguidas por la representación gráfica de las mismas. Posteriormente, se incluyen las curvas ajustadas que ilustran la probabilidad predicha de diabetes bajo diferentes combinaciones de factores.

Razones de odds

Las razones de odds permiten cuantificar la variación en la probabilidad de padecer diabetes ante cambios en las variables explicativas, manteniendo constantes las demás condiciones.