UNIVERSIDAD NACIONAL
DE ROSARIO
FACULTAD DE CIENCIAS
ECONÓMICAS Y ESTADÍSTICA



UNR

Trabajo Práctico de Modelos Lineales Generalizados

Integrantes:
Cañizares, María Inés
Zamer, Lisbeth

Licenciatura en Estadística

Año 2026

Introducción

El hundimiento del RMS Titanic, ocurrido en 1912 durante su viaje inaugural, es una de las tragedias marítimas más recordadas de la historia. Considerado el mayor transatlántico de su época y casi insumergible, su naufragio causó la muerte de más de 1.500 de las aproximadamente 2.200 personas a bordo y dejó en evidencia graves falencias de seguridad, como la escasez de botes salvavidas. El suceso provocó una conmoción mundial e impulsó cambios en la normativa internacional. Los datos de sus pasajeros permiten, además, estudiar si la supervivencia estuvo asociada a características individuales como el sexo, la edad, la tarifa abonada o el puerto de embarque, y contrastar con evidencia empírica la norma de "mujeres y niños primero".

En este trabajo se busca identificar los factores con mayor influencia en la probabilidad de supervivencia de los pasajeros, mediante un Modelo Lineal Generalizado sobre la base de datos del Titanic construida a partir de registros históricos reales.

Material y métodos

En este contexto, el presente trabajo tiene como objetivo modelar la probabilidad de supervivencia de los pasajeros del Titanic en función de sus características individuales, mediante un Modelo Lineal Generalizado con función de enlace logit. Este enfoque, permite estimar el efecto de cada variable en términos de razones de odds y evaluar posibles interacciones entre ellas.

La base de datos utilizada contiene información de 891 pasajeros. Dado que presentaba datos faltantes, se optó por eliminar las observaciones incompletas, por lo que el análisis se realizó sobre 712 observaciones. Para evaluar la capacidad predictiva del modelo, esta base se dividió en dos subconjuntos: uno de entrenamiento, con 571 observaciones, utilizado para ajustar el modelo, y uno de prueba, con las 141 restantes, reservado para evaluar su desempeño predictivo sobre datos no utilizados en el ajuste.

La variable respuesta es Survived, que indica si el pasajero sobrevivió al naufragio: toma el valor 1 si sobrevivió (SÍ) y 0 si no sobrevivió (NO). Al tratarse de una variable binaria, se asume que cada observación sigue una distribución Bernoulli, con probabilidad de éxito π, que representa la probabilidad de supervivencia.

El análisis comenzó con un estudio descriptivo de las variables, para explorar su distribución y su relación con la supervivencia. Luego se seleccionaron las variables del modelo sobre el conjunto de entrenamiento y se ajustó el modelo final con enlace logit. Se evaluó su ajuste y su capacidad predictiva sobre el conjunto de prueba. Por último, se compararon distintas funciones de enlace (logit, probit y cloglog), con el fin de identificar qué factores estuvieron más fuertemente asociados a la supervivencia.

Las variables explicativas incluidas en el análisis se describen a continuación:

- **Edad**: medida en años. Es una variable cuantitativa continua.
- **Tarifa**: precio del pasaje abonado por el pasajero, medida en libras esterlinas (£). Es una variable cuantitativa continua.
- **Embarcación**: puerto en el que el pasajero abordó el Titanic, categorizada en tres niveles:
  - "C": Cherburgo (Francia)
  - "Q": Queenstown (Irlanda, actual Cobh)
  - "S": Southampton (Inglaterra)
- **Sexo**: sexo del pasajero. Fue categorizada en dos niveles:
  - "Male": Masculino
  - "Female": Femenino

Análisis Descriptivo

A continuación se presenta una visión general de las características clave de la población estudiada.

Tabla 1: Frecuencias absolutas y relativas de supervivencia

Sobrevivió	Frecuencia	Porcentaje (%)
No	424	59.55
Sí	288	40.45
Total	712	100.00

Tabla 2: Frecuencias absolutas y relativas de sexo

Sexo	Frecuencia	Porcentaje (%)
Femenino	259	36.38
Masculino	453	63.62
Total	712	100

Tabla 3: Frecuencias absolutas y relativas de Embarcación

Embarcación	Frecuencia	Porcentaje (%)
C	130	18.26
Q	28	3.93
S	554	77.81
Total	712	100

Tabla 4: Estadísticas descriptivas de la variable edad

Variable	Media	Mediana	DE	Mínimo	Máximo
edad	29.64	28	14.49	0.42	80

Tabla 5: Estadísticas descriptivas de la variable tarifa

Variable	Media	Mediana	DE	Mínimo	Máximo
tarifa	34.57	15.64585	52.94	0	512.3292

En conjunto, en las tablas descriptivas se observa que de los 712 pasajeros considerados, 424 (59,55 %) no sobrevivieron y 288 (40,45 %) sí lo hicieron, una distribución con casos suficientes en ambas categorías para estudiar los factores asociados a la supervivencia. La mayoría de los pasajeros eran hombres (63,62 %) y la mayor cantidad de pasajeros embarcaron en Southampton (77,81 %), mientras que la categoría Queenstown quedó representada por solo 28 observaciones (3,93 %), lo que podría dar estimaciones menos precisas para ese puerto. La edad presentó una distribución aproximadamente simétrica, con media de 29,64 años y mediana de 28, y una dispersión considerable (desvío estándar de 14,49 años). La tarifa, en cambio, mostró una fuerte asimetría a la derecha, con una media (34,57) más del doble que la mediana (15,65) y valores extremos de hasta 512,33, por lo que se justifica transformarla con logaritmo antes de incluirla en el modelo. En síntesis, la muestra es adecuada para el análisis, y las características observadas, como la composición por sexo, la edad y la tarifa, son variables de interés para evaluar su asociación con la supervivencia.

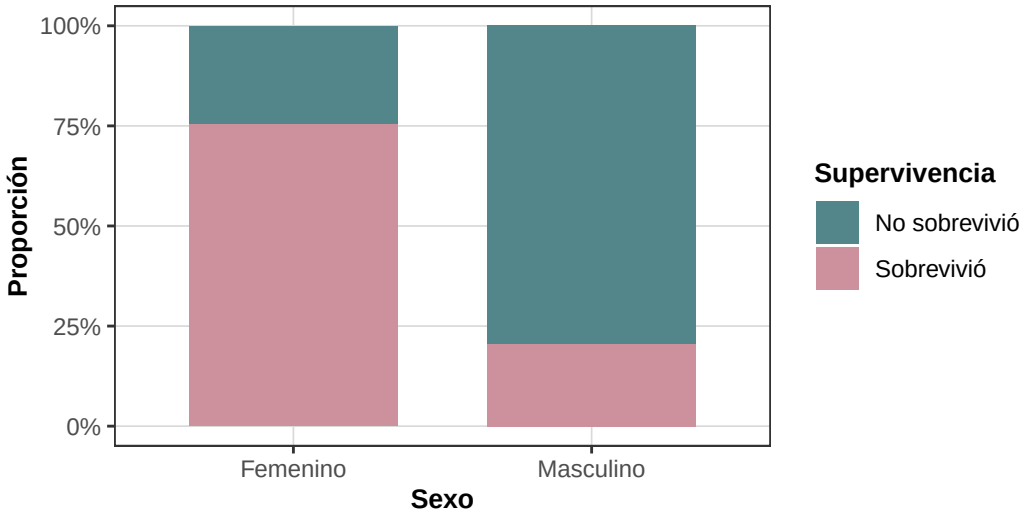


Figura 1: Proporción de pasajeros sobrevivientes según sexo

Se observa que la proporción de pasajeros que sobrevivieron es más alta para aquellos con sexo femenino en comparacón a los pasajeros masculinos.

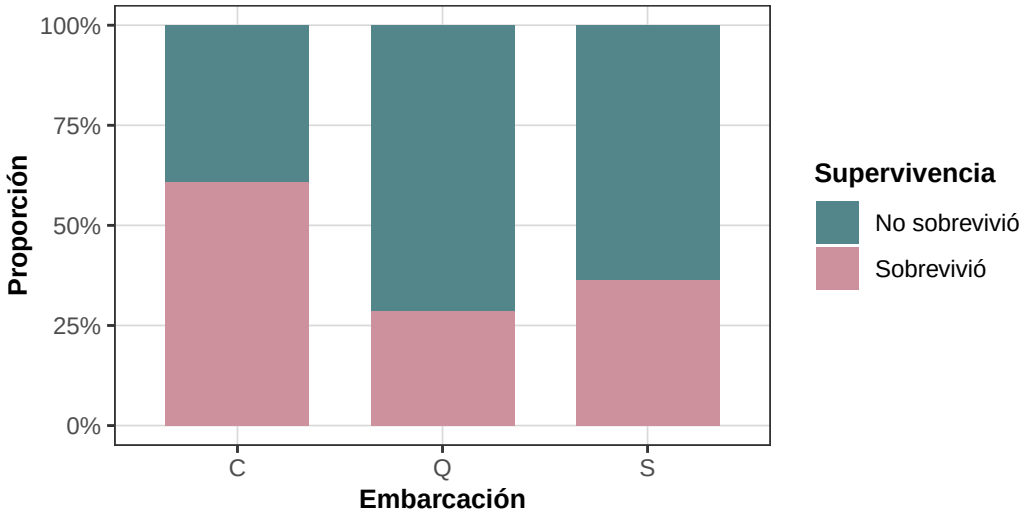


Figura 2: Proporción de pasajeros sobrevivientes según lugar de embarcación

Se observa una mayor proporción de sobrevivientes entre los pasajeros que embarcaron en C (aprox. 60 %) en comparación con Q y S (aprox. 28 % y 36 %), lo que sugiere una posible asociación entre el puerto de embarque y la supervivencia.

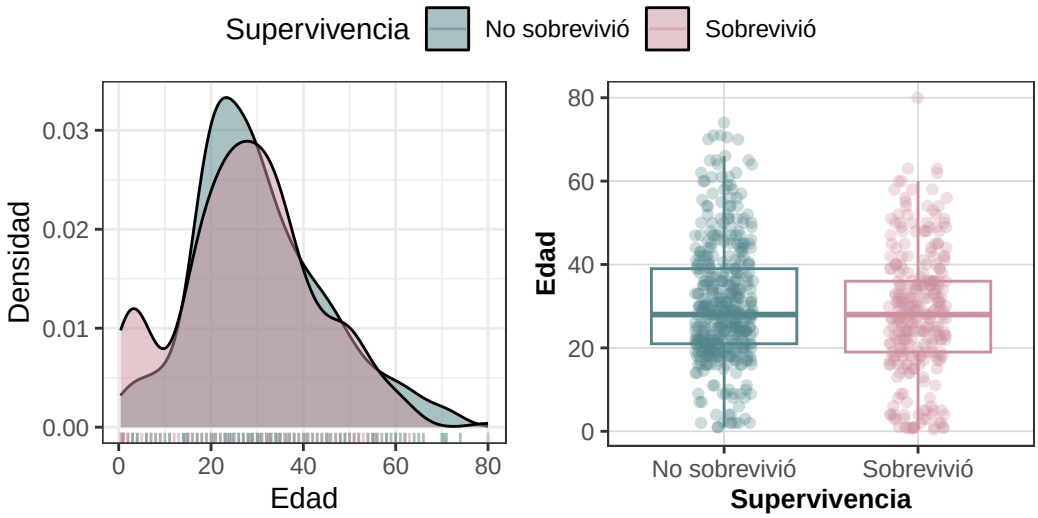


Figura 3: Distribución de la edad según supervivencia

La distribución de la edad es similar entre sobrevivientes y no sobrevivientes, con medianas casi idénticas (aprox. 28 años), por lo que la edad parece no estar fuertemente asociada a la supervivencia. Se observa, sin embargo, una mayor proporción de sobrevivientes entre los niños pequeños, y una leve mayor presencia de no sobrevivientes en edades avanzadas.

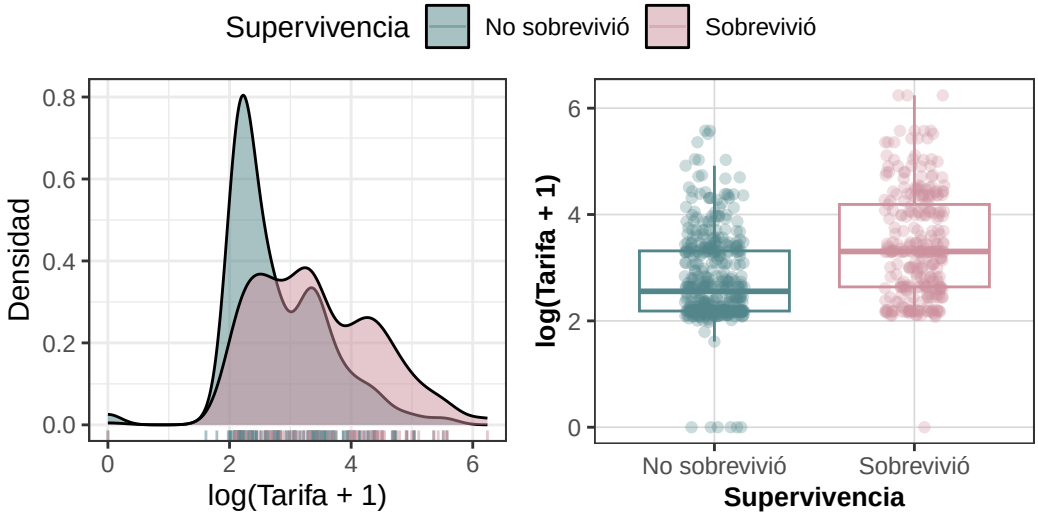


Figura 4: Distribución de la log(Tarifa) según supervivencia

La tarifa pagada parece estar asociada a la supervivencia: los pasajeros que sobrevivieron presentan en general tarifas más altas (mediana de log(Tarifa + 1) mayor) que quienes no sobrevivieron, que se concentran en tarifas bajas. Esto sugiere que la tarifa podría ser un predictor relevante de la supervivencia.

Modelado estadístico

El trabajo se realizará bajo el enfoque de modelos lineales generalizados, utilizando lo desarrollado por Nelder y Wedderburn.

Selección del modelo

Para modelar la probabilidad de supervivencia de los pasajeros del Titanic, en función de las variables explicativas sexo, edad, tarifa del pasaje y puerto de embarque, se propuso emplear un modelo con función de enlace logit.

En primer lugar, se seleccionaron las variables explicativas consideradas relevantes para explicar la supervivencia de los pasajeros y se ajustó un modelo que incluyó sus efectos principales. A continuación, se evaluó la incorporación de interacciones de segundo orden entre dichas variables, utilizando los métodos de selección hacia adelante (forward) y hacia atrás (backward), con el criterio de información de Akaike (AIC) y la deviance de cada modelo. Ambos procedimientos condujeron al mismo modelo final, que incorpora las interacciones entre sexo y edad, y entre edad y tarifa del pasaje.

Probamos linealidad de la predictoras continuas

Con el objetivo de evaluar si la relación entre la edad y el logit de la probabilidad de supervivencia podía considerarse lineal, se compararon dos modelos alternativos.

En primer lugar, se construyó un modelo que incorpora la variable edad como ordinal, dividiendo su rango en cinco categorías según los cuantiles 0.2, 0.4, 0.6 y 0.8. Posteriormente, se ajustó un segundo modelo en el que la edad se representó mediante variables indicadoras (dummies), permitiendo una relación no necesariamente lineal con la respuesta.

Finalmente, se evaluó si la incorporación de esta última variable aportaba una mejora significativa al modelo original mediante una prueba de razón de verosimilitudes.

Los resultados no proporcionaron evidencia suficiente para justificar la incorporación de la edad categorizada ($p-value = 0.19$). Por lo tanto, se decidió mantener la edad como variable continua en el modelo final.

Adicionalmente, dado que se cuenta con otra variable continua, el logaritmo de la tarifa (logTarifa), se procedió a evaluar de forma análoga si su relación con el logit de la probabilidad de supervivencia podía considerarse lineal mediante la comparación de modelos alternativos.

Se construyó también un modelo que incorpora la variable logTarifa como ordinal, dividiendo su rango en cinco categorías según los cuantiles 0.2, 0.4, 0.6 y 0.8. Posteriormente, se ajustó un segundo modelo en el que dicha variable se representó mediante variables indicadoras (dummies), permitiendo capturar una relación no necesariamente lineal con la respuesta.

Los resultados no proporcionaron evidencia suficiente para justificar la incorporación de la tarifa categorizada de forma no lineal ($p-value = 0.56$). En consecuencia, se decidió mantener logTarifa como variable continua en el modelo final.

Por lo tanto, el modelo seleccionado se expresa como:

$$\begin{aligned}\text{logit}(\pi_i) = \ln\left(\frac{\pi_i}{1-\pi_i}\right) =& \beta_0 + \beta_1\,\text{Sexo}_i + \beta_2\,\text{logTarifa}_i + \beta_3\,\text{EmbarcacionQ}_i + \beta_4\,\text{EmbarcacionS}_i + \\ &+ \beta_5\,\text{Edad}_i + \beta_6\,(\text{Sexo}_i \times \text{Edad}_i) + \beta_7\,(\text{logTarifa}_i \times \text{Edad}_i), \quad i = \overline{1,571}\end{aligned}$$

donde:

- $\text{Sexo}_i = \begin{cases} 1 & \text{si Masculino} \\ 0 & \text{si Femenino} \end{cases}$
- $\text{EmbarcaciónQ}_i = \begin{cases} 1 & \text{si Embarcación = Q} \\ 0 & \text{si en otro caso} \end{cases}$
- $\text{EmbarcaciónS}_i = \begin{cases} 1 & \text{si Embarcación = S} \\ 0 & \text{si en otro caso} \end{cases}$

Bondad del ajuste y estimación del modelo

Se evalúa la adecuación de la función de enlace logit utilizada en el modelo aplicando el test de especificación de la función de enlace, que consiste en incorporar al modelo un término adicional cuadrático del predictor lineal estimado:

El procedimiento implica ajustar un modelo extendido que incluye esta nueva variable y comparar su ajuste con el modelo original mediante una prueba de razón de verosimilitud. En este análisis, la comparación entre ambos modelos no mostró evidencia suficiente para rechazar la adecuación del enlace logit, por lo que se considera apropiado mantenerlo en el modelo final ($p - value = 0.12$).

Enlace	Parámetros	AIC
Cloglog	8	554.49
Logit	8	557.82
Probit	8	557.99

Comparación de enlaces según AIC (mismo predictor lineal)

Si bien se observa que el menor valor de Akaike es el del enlace cloglog, dado que el enlace logit es el más utilizado para respuesta binaria y tambien posee la ventaja de interpretar el modelo en terminos de razones de odds, se decide elegir este modelo para continuar con el análisis ya que en el test de adecuación del enlace el logit es adecuado.

Además, para evaluar la bondad de ajuste del modelo, se aplicó la prueba de Hosmer y Lemeshow. Esta prueba compara las frecuencias observadas y esperadas del evento de interés en grupos formados a partir de los valores predichos por el modelo y dado el tamaño muestral disponible, se optó por dividir las observaciones en 10 grupos de igual tamaño según los valores de probabilidad predicha. Finalmente, se concluye que el modelo presenta un ajuste adecuado a los datos ($p - value = 0.46$).

Considerando los resultados del estudio del modelo a través de los diferentes tests de hipótesis, el ajuste realizado es el siguiente:

$$\begin{aligned}\text{logit}(\widehat{\pi}_i) = \ln\left(\frac{\widehat{\pi}_i}{1-\widehat{\pi}_i}\right) = 0.76 - 0.93\,\text{Sexo}_i + 0.12\,\text{logTarifa}_i - 1.12\,\text{EmbarcacionQ}_i - 0.62\,\text{EmbarcacionS}_i - \\ - 0.045\,\text{Edad}_i - 0.05\,(\text{Sexo}_i \times \text{Edad}_i) + 0.019\,(\text{logTarifa}_i \times \text{Edad}_i), \quad i = \overline{1,571}\end{aligned}$$

Análisis de residuos

El análisis de residuos permite evaluar la adecuación del modelo ajustado, tanto en lo que respecta a la componente sistemática como a la aleatoria.

Con el objetivo de analizar la estructura del modelo, se construyó el gráfico de los residuos cuantil frente a las probabilidades estimadas bajo el enlace logit.

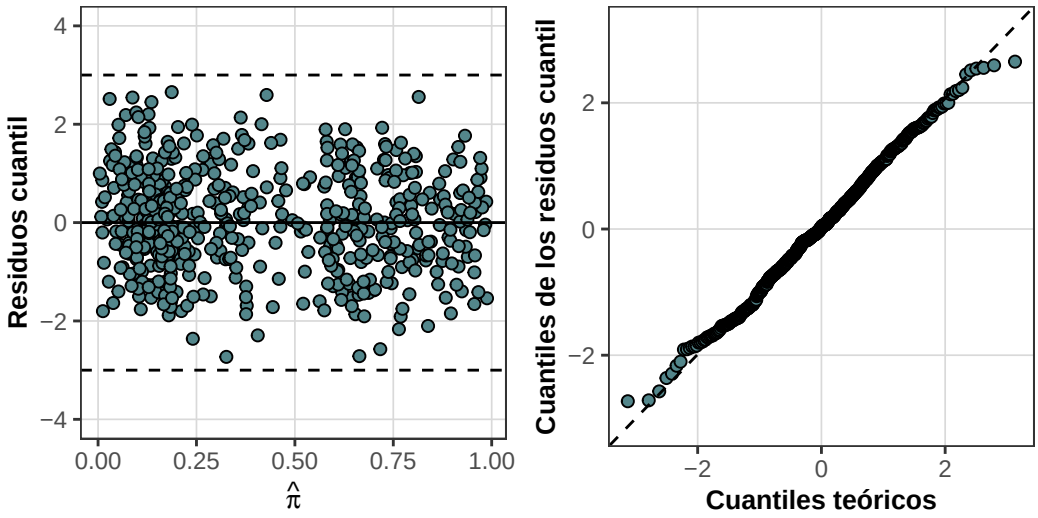


Figura 5: Análisis de residuos

En el gráfico de residuos cuantil contra las probabilidades estimadas se observa que los residuos se distribuyen aproximadamente alrededor de cero, sin un patrón sistemático definido. Aunque hay una mayor concentración de observaciones en las probabilidades estimadas más bajas, no se identifican tendencias claras que indiquen problemas importantes de ajuste, lo que sugiere que la función de enlace logit es adecuada. Además, para verificar la distribución supuesta de

los errores, se empleó el gráfico probabilístico normal de los residuos cuantil, donde los puntos se alinean adecuadamente con la línea de referencia, con leves desviaciones en los extremos. En conjunto, no se evidencian desvíos sistemáticos importantes, por lo que el modelo presenta un ajuste globalmente satisfactorio.

Estudio de la capacidad predictiva del modelo

La capacidad predictiva del modelo se evaluó sobre el conjunto de validación, es decir, sobre pasajeros que no participaron en la estimación de los parámetros, de modo de obtener una medida de desempeño que no esté sesgada por el ajuste. Con las probabilidades de supervivencia estimadas para esas observaciones, se construyó la curva ROC, que muestra cómo varían la sensibilidad (tasa de verdaderos positivos) y la tasa de falsos positivos (1 - especificidad) al modificar el punto de corte de clasificación. Esta curva permite analizar el equilibrio entre ambos tipos de acierto y error, y es una herramienta útil para elegir un umbral de clasificación adecuado. Complementariamente, se calculó el área bajo la curva (AUC) como resumen de la capacidad discriminante del modelo.

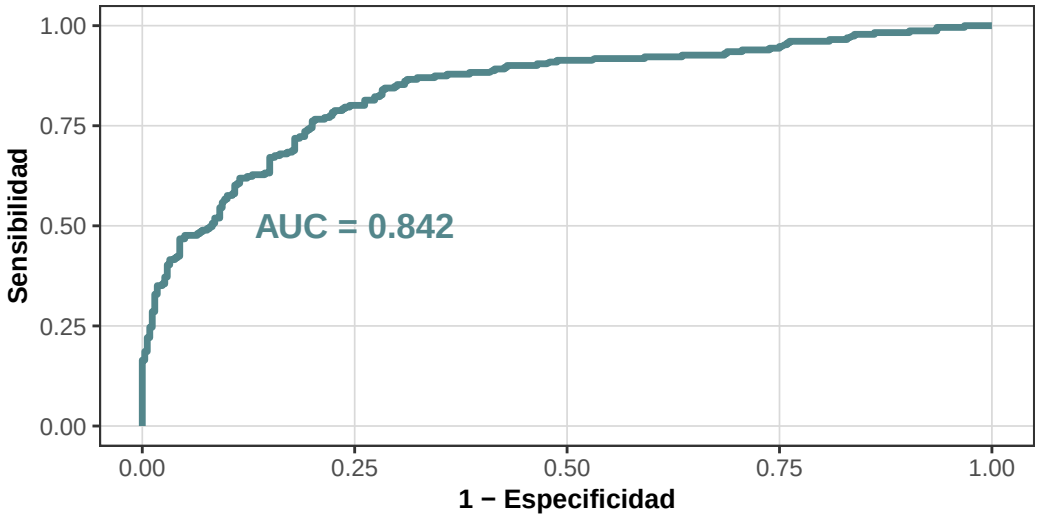


Figura 6: Curva ROC

El punto de corte seleccionado fue de 0.842, correspondiente al valor que maximiza simultáneamente la sensibilidad y la especificidad del modelo. Con este umbral se obtuvo la siguiente matriz de confusión, que resume el desempeño del modelo en la clasificación de los casos:

Predicho / Observado	**No Sobrevivió**	**Sobrevivió**
No Sobrevivió	69	13
Sobrevivió	15	44

El modelo logró clasificar correctamente al 80 % de las observaciones del conjunto de validación, con una sensibilidad del 77 % (proporción de sobrevivientes correctamente identificados) y una especificidad del 82.1 % (proporción de no sobrevivientes correctamente clasificados).

Resultados

En esta sección se presentan los principales hallazgos obtenidos a partir del modelo final ajustado. En primer lugar, se exponen las razones de odds estimadas para cada variable significativa, seguidas por la representación gráfica de las mismas.

Razones de odds

Las razones de odds permiten cuantificar la variación en la probabilidad de sobrevivir ante cambios en las variables explicativas, manteniendo constantes las demás condiciones.

Tabla 7: Razones de odds e intervalos de confianza del 0.95 (Wald)

Contraste	RO	IC inferior	IC superior
Embarque Q vs. C	0.327	0.093	1.155
Embarque S vs. C	0.540	0.308	0.946
Sexo (masc. vs. fem.) a los 28 años	0.097	0.062	0.150
Edad (X+5 vs. X) en mujeres, logFare = 2.81	1.044	0.911	1.196
Edad (X+5 vs. X) en hombres, logFare = 2.81	0.812	0.721	0.915
logFare (X+1 vs. X) a los 28 años	1.919	1.490	2.472

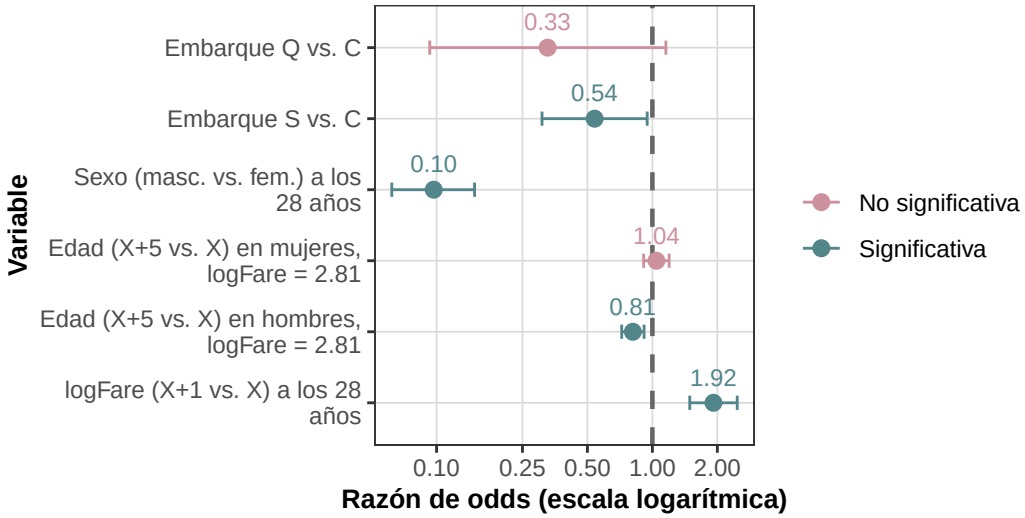


Figura 7: Forest plot de Razones de odds (cambios en edad por 5 años)

De la Tabla 7 y la Figura 7 se extrae que:

- La chance de sobrevivir de quienes embarcaron en S es entre un 5,4 % y un 69,2 % menor que la de quienes embarcaron en C, para el mismo sexo, edad y tarifa.
- La chance de sobrevivir de los hombres de 28 años es entre un 85 % y un 93,8 % menor que la de las mujeres de 28 años, para el mismo puerto de embarque y niveles fijos de tarifa.
- La chance de sobrevivir de un hombre de determinada edad es entre un 8,5 % y un 27,9 % menor que la de un hombre 5 años menor, para el mismo puerto y logFare fijo.
- La chance de sobrevivir de una persona de 28 años con logFare = X + 1 es entre un 49 % y un 147,2 % mayor que la de una persona de 28 años con logFare = X, para el mismo sexo y puerto.

Conclusión

El presente trabajo permitió ajustar y evaluar un modelo lineal generalizado con enlace logit para estudiar los factores asociados a la supervivencia de los pasajeros. A través de un proceso de selección, diagnóstico y validación, se obtuvo un modelo final con el sexo, la edad, la tarifa y el puerto de embarque como variables explicativas.

El análisis evidenció que el sexo, la tarifa y el puerto de embarque contribuyen a explicar la probabilidad de sobrevivir. Los hombres tuvieron una chance de sobrevivir mucho menor que las mujeres, mientras que una tarifa más alta se asoció con una mayor chance de supervivencia. Además, los pasajeros que embarcaron en Southampton, Inglaterra tuvieron una chance menor que los que embarcaron en Cherburgo, Francia. El efecto de la edad dependió del sexo: no fue significativo en las mujeres, pero en los hombres a mayor edad menor fue la chance de sobrevivir. La validación del modelo, mediante la curva ROC y la matriz de confusión, mostró una capacidad predictiva adecuada, confirmando su utilidad para clasificar a los pasajeros según su supervivencia.